




# Fundamentos de Procesamiento de Lenguaje Natural (PLN)

Objetivo: entender qué es PLN, sus aplicaciones principales y cómo preparar texto para modelos de machine learning e inteligencia artificial de manera efectiva.

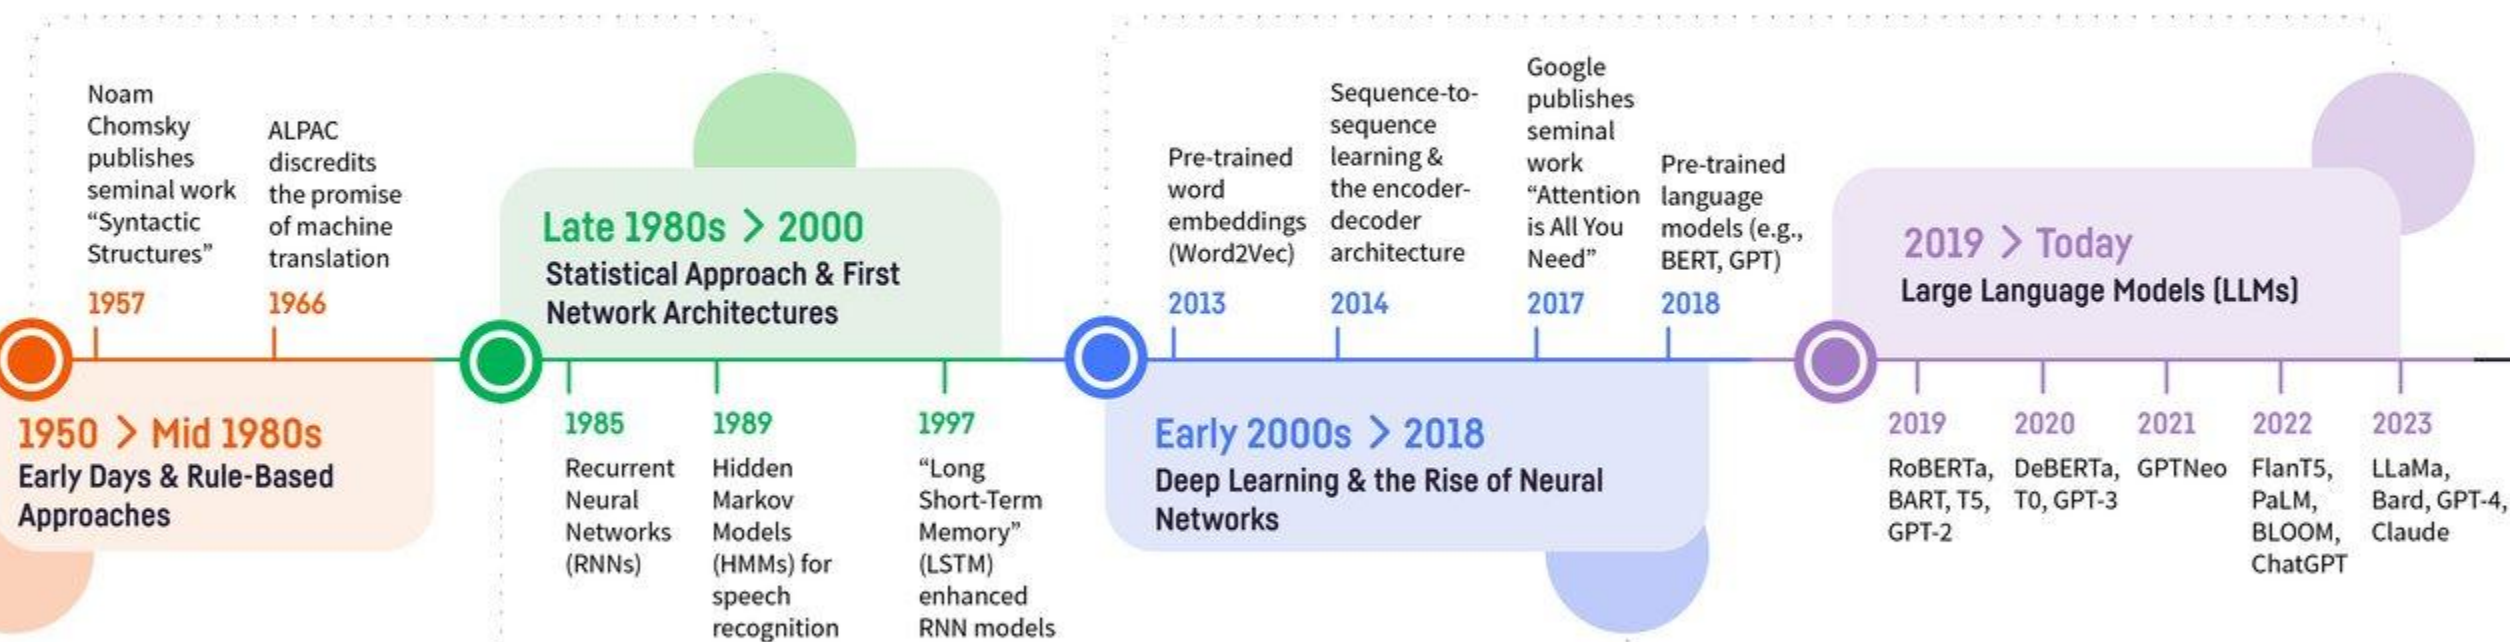
# ¿Qué es el PLN?

El Procesamiento de Lenguaje Natural es una rama fascinante de la inteligencia artificial que permite a las máquinas **entender, interpretar y generar lenguaje humano** de forma natural y contextual.

Esta disciplina revolucionaria une la lingüística tradicional con la computación avanzada, creando un puente entre la comunicación humana y la comprensión artificial.



# The History of NLP



# Historia del PLN



# Aplicaciones Actuales del PLN



## Motores de Búsqueda

Google y Bing utilizan PLN para entender consultas complejas y ofrecer resultados más precisos y contextuales.



## Asistentes Virtuales

Siri, Alexa y Google Assistant procesan comandos de voz y mantienen conversaciones naturales con usuarios.



## Chatbots de Servicio

Sistemas automatizados que brindan atención al cliente 24/7 con respuestas inteligentes y personalizadas.



## Análisis de Sentimiento

Monitoreo de opiniones en redes sociales para entender percepción de marca y tendencias del mercado.



## Traducción Automática

Google Translate y sistemas similares rompen barreras idiomáticas con traducciones cada vez más precisas.



# Principales Retos del PLN

## Ambigüedad Semántica

Una palabra puede tener múltiples significados: "banco" puede referirse a una institución financiera o a un asiento en el parque.

## Sarcasmo e Ironía

Detectar cuando el significado real es opuesto al literal representa uno de los desafíos más complejos.

## Morfología Compleja

Idiomas como el español tienen conjugaciones, géneros y variaciones que complican el análisis automático.

## Jerga y Emojis

El lenguaje informal, abreviaturas de internet y emojis cambian constantemente y requieren adaptación continua.



# Los 5 Componentes Fundamentales del PLN



Cada nivel construye sobre el anterior, desde la estructura básica de palabras hasta el significado completo del discurso.


# Lenguaje Natural vs. Lenguaje Formal

## Lenguaje Natural



- Ambiguo por naturaleza
- Redundante y flexible
- Contextualmente dependiente
- Rico en matices emocionales

## Lenguaje Formal



- Preciso y específico
- Sin ambigüedades
- Reglas estrictas
- Lógicamente consistente



# Flujo Típico de un Sistema PLN



## Recolección de Texto

Obtención de datos textuales desde diversas fuentes como documentos, web o redes sociales.



## Preprocesamiento

Limpieza y normalización del texto para prepararlo para el análisis automatizado.



## Representación

Conversión del texto en formatos numéricos: bolsa de palabras, embeddings o vectores.



## Modelo de ML/IA

Aplicación de algoritmos de aprendizaje automático para extraer patrones y generar predicciones.



## Evaluación y Aplicación

Validación de resultados y implementación del sistema en aplicaciones reales.



# Preprocesamiento de Texto

## El Paso Crítico

El preprocesamiento es una etapa fundamental antes de entrenar cualquier modelo de machine learning. Su objetivo principal es **limpiar y transformar el texto** para que sea completamente entendible por la máquina.

Sin un preprocesamiento adecuado, incluso los modelos más sofisticados pueden fallar en producir resultados precisos y útiles.

# Normalización de Texto: Técnicas Esenciales

Aa

---

## Conversión a Minúsculas

Estandariza todo el texto para evitar que "Casa" y "casa" sean tratadas como palabras diferentes.

,

---

## Eliminación de Puntuación

Remueve comas, puntos y otros signos que pueden interferir con el análisis de patrones.

#

---

## Tratamiento de Números

Decide si eliminar, reemplazar o conservar números dependiendo del contexto específico del proyecto.

Estas técnicas de normalización son la base para crear datasets de entrenamiento consistentes y efectivos para modelos de PLN.



# Tokenización

La tokenización es el proceso fundamental de dividir texto en **unidades más pequeñas y manejables** llamadas tokens. Estas unidades pueden ser palabras, caracteres o subpalabras según el contexto de aplicación.

## Texto original

"Los árboles son verdes."

## Tokens resultantes

["los", "árboles", "son", "verdes"]

Este proceso permite que las máquinas procesen el lenguaje humano de manera sistemática y estructurada.



# Stopwords

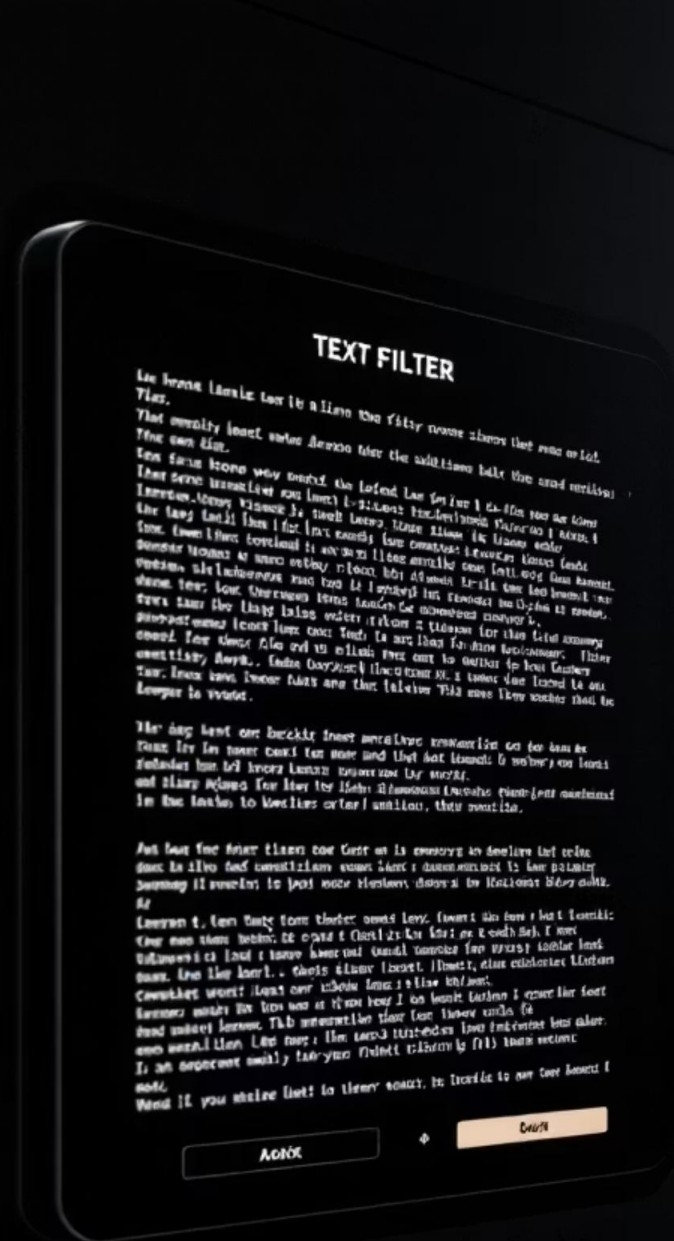
Las stopwords son palabras muy frecuentes que aparecen en la mayoría de textos pero aportan poco valor semántico al análisis. Su eliminación reduce el ruido y mejora la eficiencia del procesamiento.

## Ejemplos comunes en español

- "el", "la", "los", "las"
- "y", "o", "pero", "de"
- "en", "con", "por", "para"

## Beneficios de eliminarlas

- Reduce dimensionalidad
- Mejora rendimiento
- Enfoca en contenido relevante



# Stemming

El stemming es una técnica que reduce palabras a su raíz morfológica mediante algoritmos simples. Aunque rápido y eficiente, puede generar raíces que no son palabras reales.

1

Palabras originales

"jugando", "jugador", "jugamos"


2

Raíz común

"jug"

📋 **Ventaja:** Proceso rápido y simple. **Desventaja:** Puede producir formas inexistentes o ambiguas que afecten el significado.





# Lemmatización

La lemmatización utiliza **conocimiento lingüístico avanzado** para reducir palabras a su forma canónica o lema. Este proceso considera el contexto gramatical y produce resultados más precisos.

01

---

## Análisis morfológico

Identifica categoría gramatical

02

---

## Aplicación de reglas

Usa diccionarios lingüísticos

03

---

## Resultado final

"jugando" → "jugar", "mejores" → "mejor"

# Representación de Texto

Convertir texto en **representaciones numéricas** es esencial para que los algoritmos de machine learning puedan procesarlo. Existen múltiples enfoques con diferentes niveles de sofisticación.



## Bolsa de Palabras (BoW)

Cuenta la frecuencia de cada palabra sin considerar orden ni contexto



## TF-IDF

Pondera la frecuencia según la importancia relativa en el corpus completo



## Word Embeddings

Representaciones vectoriales densas que capturan relaciones semánticas







# Ejemplo Práctico: BoW vs TF-IDF

## Textos de ejemplo

Texto 1: "El gato duerme en la cama."

Texto 2: "El perro duerme en la alfombra."

## Análisis BoW

Cuenta simple: ["gato":1, "perro":1, "duerme":2, "el":2]

## Análisis TF-IDF

Mayor peso a palabras únicas como "gato" y "perro" que distinguen los textos

Mientras BoW trata todas las palabras por igual, TF-IDF **identifica términos distintivos** que mejor caracterizan cada documento.

# Embeddings Modernos

Los embeddings basados en **Deep Learning** revolucionaron el PLN al capturar relaciones semánticas complejas en espacios vectoriales de alta dimensión.

## Relaciones analógicas

"Rey - Hombre + Mujer  $\approx$  Reina"



## Similitud semántica

Palabras relacionadas quedan próximas en el espacio vectorial

## Contexto dinámico

Modelos como BERT consideran el contexto específico

# Idiomas con declinaciones

Alemán, ruso: Múltiples formas de una palabra según función gramatical

Chino, japonés: Requieren segmentación especial para identificar palabras

Tildes, conjugaciones, género: Rica morfología que complica la normalización



# Herramientas para PLN

El ecosistema de herramientas PLN ofrece **soluciones especializadas** para cada nivel de complejidad, desde análisis básico hasta modelos de última generación.



## Librerías Python tradicionales

NLTK, spaCy, gensim, scikit-learn proporcionan funcionalidades robustas para preprocesamiento, análisis y modelado básico.



## Frameworks Deep Learning

TensorFlow, PyTorch, HuggingFace permiten crear y entrenar modelos neuronales avanzados desde cero.



## APIs y pipelines listos

OpenAI API, spaCy pipelines ofrecen soluciones inmediatas para aplicaciones comerciales rápidas.



# Conclusiones

## ■ PLN: pilar de la IA moderna

El procesamiento de lenguaje natural es fundamental para crear sistemas inteligentes que comprendan y generen texto humano

## ■ Preprocesamiento: base sólida

La calidad del preprocesamiento determina directamente el éxito de cualquier aplicación de PLN

## ■ Técnicas complementarias

Stemming y lematización se complementan con representaciones modernas como embeddings

## ■ Aplicaciones ilimitadas

Estos fundamentos habilitan la construcción de clasificadores, chatbots, traductores y sistemas conversacionales

